Premična pika

$$x = (-1)^{S} m \cdot b^{e}$$

$$m = c_{0} + c_{1}b^{-1} + c_{2}b^{-2} + \dots + c_{t}b^{-t}$$

S ... predznak

b ... baza, ponavadi 2

m ... vrednost mantise

t ... dolžina mantise

e ... vrednost eksponenta $L \le e \le U$

 c_i ... števke v mejah $0 < c_i < b-1$

Sistem premične pike označimo z P(b, t, L, U).

Standard IEEE

Eksponent je zapisan z odmikom:

$$E = e + \text{odmik}$$

Če je E=0, uporabimo **denormiran zapis**:

$$x = (-1)^S (c_1 b^{-1} + c_2 b^{-2} + \dots + c_t b^{-t}) \cdot b^{e+1}$$

Sicer pa **normiran zapis**:

$$x = (-1)^{S} (1 + c_1 b^{-1} + c_2 b^{-2} + \dots + c_t b^{-t}) \cdot b^{e}$$

Če so vsi biti eksponenta 1 in vsi biti mantise 0, je $x = (-1)^S \infty$.

Če so vis biti eksponenta 1 in vsi biti mantise niso 0, je x = NaN.

• Single precision b = 2, t = 23, L = -126, U = 127, odmik: 127

preazitak i exportent o mantisa 25	predznak 1	exponent 8	mantisa 23
--	------------	------------	------------

• Double precision b = 2, t = 52, L = -1022, U = 1023, odmik: 1023

predznak 1	exponent 11	mantisa 52

Zaokroževanje

Naj bo x pozitivno število z neskončnim zapisom $x = (c_1b^{-1} + c_2b^{-2} + \cdots + c_tb^{-t} + c_{t+1}b^{-t-1}) + \cdots b^e$

Kandidata za približek fl(x) sta:

$$x_{-} = (c_1b^{-1} + c_2b^{-2} + \dots + c_tb^{-t})b^e$$

$$x_{+} = (c_1b^{-1} + c_2b^{-2} + \dots + c_tb^{-t} + b^{-t})b^e$$

Vzamemo tistega, ki je bljižje. Če sta enako blizu, izberemo tistega, ki ima zadnjo števko sodo.

Osnovna zaokrožitvena napaka

$$u = \frac{1}{2}b^{-t}$$

$$fl(x) = x(1+\delta) \quad \text{za} \quad |\delta| \le u$$

$$\frac{|fl(x) - x|}{|x|} \le u$$

Napake pri numeričnem računanju

• Neodstranljiva napaka Namesto x imamo približek \bar{x} .

$$D_n = f(x) - f(\bar{x})$$

• Napaka metode Namesto funkcije f imamo približek a.

$$D_m = f(\bar{x}) - g(\bar{x})$$

• Zaokrožitvena napaka Pri računanju $\tilde{y} = f(\bar{x})$ se pri vsaki operaciji se pojavi zaokrožitvena napaka. Namesto \tilde{y} dobimo \hat{y} .

$$D_z = \tilde{y} - \hat{y}$$

Celotna napaka je $D = |D_n| + |D_m| + |D_z|$.

Stopnja občutljivosti

Razmerje velikosti spremembe podatkov in spremembe rezultata.

Naj bo $f: \mathbb{R} \to \mathbb{R}$ zvezno odvedlijva funkcija in δx majhna motnja.

• Absolutna občutljivost f v točki x:

$$|f(x + \delta x) - f(x)| \approx |f'(x)| \cdot |\delta x|$$

• Relativna občutliivost f v točki x:

$$\frac{|f(x+\delta x) - f(x)|}{|f(x)|} \approx \frac{|f'(x)| \cdot |\delta x|}{|f(x)|}$$

Obratna in direktna stabilnost

- Direktna stabilnost: za vsak x direktna napaka $(|f(x) f(x + \Delta x)|)$ majhna (absolutno oz. relativno).
- Obratna stabilnost: za vsak x razlika Δx , ki bi nam dala pravi rezultat majhna.

|direktna napaka| ≤ občutlijvost · |obratna napaka|

Nelinearne enačbe

Iščemo ničle funkcije f.

• Enostavne ničle:

$$f(\alpha) = 0$$
 in $f'(\alpha) \neq 0$

• m-kratne ničle:

$$f(\alpha) = f'(\alpha) = \dots = f^{(m-1)}(\alpha) = 0$$

Občutljivost ničle

Naj bo α *m*-kratna ničla $\hat{\alpha}$ približek, da je $f(\hat{\alpha}) = \varepsilon$.

Če f razvijemo v Taylorjevo vrsto okoli α in vzamemo prvih m+1 členov dobimo:

$$\varepsilon \doteq \frac{f^{(m)}(\alpha)}{m!} (\hat{\alpha} - \alpha)^m \quad |\hat{\alpha} - \alpha| \doteq \sqrt[m]{\frac{\varepsilon \cdot m!}{|f^{(m)}(\alpha)|}}$$

Bisekcija

 $\textit{vhod}\colon$ funkcija $f:[a,b]\to\mathbb{R},\,f(a)f(b)<0,$ natancnost ε $\textit{izhod}\colon$ nicla funkcije f

$$\begin{aligned} & \textit{dokler} \quad |b-a| > \varepsilon \colon \\ & c \leftarrow \frac{a+b}{2} \\ & c \quad \text{sign}(f(c)) = \text{sign}(f(a)) \colon \\ & a \leftarrow c \\ & \textit{sicer} \colon \\ & b \leftarrow c \end{aligned}$$

c je približek ničle α . Velja

$$|\alpha - c| \le \frac{b - a}{2^m} \le \varepsilon$$

Za natančnost ε potrebujemo $\log_2\left(\frac{b-a}{\varepsilon}\right)$ korakov.

Navadna iteracija

Rešujemo f(x) = 0. Enačbo pretvorimo vx = g(x). Načinov je veliko:

- g(x) = f(x) + x
- g(x) = cf(x) + x
- g(x) = h(x)f(x) + x kjer je h(x) funkcija, ki nima ničle v α .

Izrek o konvergenci navadne iteracije

Naj bo α negibna točka za g in naj g na intervalu $[\alpha - d, \alpha + d]$ (d > 0) zadošča Lipschitzovemu pogoju:

$$\exists m \in [0,1) \ \forall x, y \in I : |g(x) - g(y)| \le m|x - y|$$

tedaj je g skrčitev na I.

Potem za vsak $x_0 \in I$ zaporedje $x_{r+1} = g(x_r)$ konvergira k α in velja:

$$|x_r - \alpha| \le \frac{m}{1 - m} |x_r - x_{r-1}|$$

Posledica: Če je g zvezno odvedljiva v α in velja $g'(\alpha) < 1$, obstaja interval I, ki vsebuje α , da za vsak $x_0 \in I$ zaporedje konvergira k α .

- Če je $|q'(\alpha)| < 1$, je α privlačna negibna točka
- Če je $|q'(\alpha)| > 1$, je α odbojna negibna točka

Če je α odbojna za g, je privlačna za g^{-1} : $g(x) = x \implies x = g^{-1}(x)$

Hitrost konvergence

p>0 je red konvergence, če $\exists C_1,C_2>0$, da za vse dovolj pozne člene zaporedja $x_{r+1}=g(x_r)$ velja:

$$C_1|x_r - \alpha|^p \le |x_{r+1} - \alpha| \le C_2|x_r - \alpha|^p$$

 $Vsak\ korak\ se\ \check{s}t.\ decimalk\ pomno\check{z}i\ s\ p.$

Naj bo g v okolici α p-krat zvezno odvedlijva in naj velja $g(\alpha) = \alpha$, $g'(\alpha) = \cdots = g^{(p-1)}(\alpha) = 0$ in $g^{(p)}(\alpha) \neq 0$. Tedaj je red konvergence enak p.

Standardni redi konvergence

p=1 ... linearna konvergenca p=2 ... kvadratična konvergenca

Tangentna (Newtonova) metoda

$$x_{r+1} = x_r - \frac{f(x_r)}{r}$$

Red konvergence:

- 2, če je α enkratna ničla $f'(\alpha) \neq 0$
- 3, če je $f'(\alpha) \neq 0$ in $f''(\alpha) = 0$
- 1. če je α večkratna ničla $f'(\alpha) = 0$

Sekantna metoda

$$x_{r+1} = x_r - \frac{f(x_r)}{\frac{f(x_r) - f(x_{r-1})}{x_r - x_{r-1}}}$$

Red konvergence: $\frac{\sqrt{5}+1}{2} \approx 1.62$

Metoda (f, f', f'')

$$x_{r+1} = x_r - \frac{f(x_r)}{f'(x_r)} - \frac{f''(x_r)f^2(x_r)}{2f'^3(x_r)}$$

Red konvergence: 3 (pri predpostavkah)

Müllerjeva metoda

$$x_{r+1} = x_r - \frac{2c}{b + \operatorname{sign}(b)\sqrt{b^2 - 4ac}}$$

Na x_r, x_{r-1}, x_{r-2} napnemo parabolo, ničla parabole je naslednji približek.

 $p(x) = a(x - x_r)^2 + b(x - x_r) + c$

Hallejeva metoda

$$x_{r+1} = x_r - \frac{2f(x_r)f'(x_r)}{2f'(x_r)^2 - f(x)f''(x)}$$