# Premična pika

$$x = (-1)^{S} m \cdot b^{e}$$

$$m = c_{0} + c_{1}b^{-1} + c_{2}b^{-2} + \dots + c_{t}b^{-t}$$

S ... predznak

b ... baza, ponavadi 2

m ... vrednost mantise

t ... dolžina mantise

e ... vrednost eksponenta  $L \le e \le U$ 

 $c_i$  ... števke v mejah  $0 < c_i < b-1$ 

Sistem premične pike označimo z P(b, t, L, U).

#### Standard IEEE

Eksponent je zapisan z odmikom:

$$E = e + \text{odmik}$$

Če je E=0, uporabimo **denormiran zapis**:

$$x = (-1)^S (c_1 b^{-1} + c_2 b^{-2} + \dots + c_t b^{-t}) \cdot b^{e+1}$$

Sicer pa **normiran zapis**:

$$x = (-1)^{S} (1 + c_1 b^{-1} + c_2 b^{-2} + \dots + c_t b^{-t}) \cdot b^{e}$$

Če so vsi biti eksponenta 1 in vsi biti mantise 0, je  $x = (-1)^S \infty$ .

Če so vis biti eksponenta 1 in vsi biti mantise niso 0, je x = NaN.

• Single precision b = 2, t = 23, L = -126, U = 127, odmik: 127

preazitak i   exportent o   mantisa 25	predznak 1	exponent 8	mantisa 23
--	------------	------------	------------

• Double precision b = 2, t = 52, L = -1022, U = 1023, odmik: 1023

predznak 1	exponent 11	mantisa 52

# Zaokroževanje

Naj bo x pozitivno število z neskončnim zapisom  $x = (c_1b^{-1} + c_2b^{-2} + \cdots + c_tb^{-t} + c_{t+1}b^{-t-1}) + \cdots b^e$ 

Kandidata za približek fl(x) sta:

$$x_{-} = (c_1b^{-1} + c_2b^{-2} + \dots + c_tb^{-t})b^e$$
  
$$x_{+} = (c_1b^{-1} + c_2b^{-2} + \dots + c_tb^{-t} + b^{-t})b^e$$

Vzamemo tistega, ki je bljižje. Če sta enako blizu, izberemo tistega, ki ima zadnjo števko sodo.

#### Osnovna zaokrožitvena napaka

$$u = \frac{1}{2}b^{-t}$$
 
$$fl(x) = x(1+\delta) \quad \text{za} \quad |\delta| \le u$$
 
$$\frac{|fl(x) - x|}{|x|} \le u$$

# Napake pri numeričnem računanju

• Neodstranljiva napaka Namesto x imamo približek  $\bar{x}$ .

$$D_n = f(x) - f(\bar{x})$$

• Napaka metode Namesto funkcije f imamo približek a.

$$D_m = f(\bar{x}) - g(\bar{x})$$

• Zaokrožitvena napaka Pri računanju  $\tilde{y} = f(\bar{x})$  se pri vsaki operaciji se pojavi zaokrožitvena napaka. Namesto  $\tilde{y}$  dobimo  $\hat{y}$ .

$$D_z = \tilde{y} - \hat{y}$$

Celotna napaka je  $D = |D_n| + |D_m| + |D_z|$ .

### Stopnja občutljivosti

Razmerje velikosti spremembe podatkov in spremembe rezultata.

Naj bo  $f: \mathbb{R} \to \mathbb{R}$  zvezno odvedlijva funkcija in  $\delta x$  majhna motnja.

• Absolutna občutljivost f v točki x:

$$|f(x + \delta x) - f(x)| \approx |f'(x)| \cdot |\delta x|$$

• Relativna občutliivost f v točki x:

$$\frac{|f(x+\delta x) - f(x)|}{|f(x)|} \approx \frac{|f'(x)| \cdot |\delta x|}{|f(x)|}$$

#### Obratna in direktna stabilnost

- Direktna stabilnost: za vsak x direktna napaka  $(|f(x) f(x + \Delta x)|)$  majhna (absolutno oz. relativno).
- Obratna stabilnost: za vsak x razlika  $\Delta x$ , ki bi nam dala pravi rezultat majhna.

|direktna napaka| ≤ občutlijvost · |obratna napaka|

## Nelinearne enačbe

Iščemo ničle funkcije f.

• Enostavne ničle:

$$f(\alpha) = 0$$
 in  $f'(\alpha) \neq 0$ 

• m-kratne ničle:

$$f(\alpha) = f'(\alpha) = \dots = f^{(m-1)}(\alpha) = 0$$

## Občutljivost ničle

Naj bo  $\alpha$  *m*-kratna ničla  $\hat{\alpha}$  približek, da je  $f(\hat{\alpha}) = \varepsilon$ .

Če f razvijemo v Taylorjevo vrsto okoli  $\alpha$  in vzamemo prvih m+1 členov dobimo:

$$\varepsilon \doteq \frac{f^{(m)}(\alpha)}{m!} (\hat{\alpha} - \alpha)^m \quad |\hat{\alpha} - \alpha| \doteq \sqrt[m]{\frac{\varepsilon \cdot m!}{|f^{(m)}(\alpha)|}}$$

## Bisekcija

 $\textit{vhod}\colon$  funkcija  $f:[a,b]\to\mathbb{R},\,f(a)f(b)<0,$ natancnost $\varepsilon$   $\textit{izhod}\colon$ nicla funkcije f

$$\begin{aligned} & \textit{dokler} \quad |b-a| > \varepsilon \colon \\ & c \leftarrow \frac{a+b}{2} \\ & c \quad \text{sign}(f(c)) = \text{sign}(f(a)) \colon \\ & a \leftarrow c \\ & \textit{sicer} \colon \\ & b \leftarrow c \end{aligned}$$

c je približek ničle  $\alpha$ . Velja

$$|\alpha - c| \le \frac{b - a}{2^m} \le \varepsilon$$

Za natančnost  $\varepsilon$  potrebujemo  $\log_2\left(\frac{b-a}{\varepsilon}\right)$  korakov.

#### Navadna iteracija

Rešujemo f(x) = 0. Enačbo pretvorimo vx = g(x). Načinov je veliko:

- g(x) = f(x) + x
- g(x) = cf(x) + x
- g(x) = h(x)f(x) + x kjer je h(x) funkcija, ki nima ničle v  $\alpha$ .

#### Izrek o konvergenci navadne iteracije

Naj bo  $\alpha$  negibna točka za g in naj g na intervalu  $[\alpha - d, \alpha + d]$  (d > 0) zadošča Lipschitzovemu pogoju:

$$\exists m \in [0,1) \ \forall x, y \in I : |g(x) - g(y)| \le m|x - y|$$

tedaj je g skrčitev na I.

Potem za vsak  $x_0 \in I$  zaporedje  $x_{r+1} = g(x_r)$  konvergira k $\alpha$  in velja:

$$|x_r - \alpha| \le \frac{m}{1 - m} |x_r - x_{r-1}|$$

Posledica: Če je g zvezno odvedljiva v  $\alpha$  in velja  $g'(\alpha) < 1$ , obstaja interval I, ki vsebuje  $\alpha$ , da za vsak  $x_0 \in I$  zaporedje konvergira k  $\alpha$ .

- Če je  $|q'(\alpha)| < 1$ , je  $\alpha$  privlačna negibna točka
- Če je  $|q'(\alpha)| > 1$ , je  $\alpha$  odbojna negibna točka

Če je  $\alpha$  odbojna za g, je privlačna za  $g^{-1}$ :  $g(x) = x \implies x = g^{-1}(x)$ 

#### Hitrost konvergence

p>0 je red konvergence, če  $\exists C_1,C_2>0$ , da za vse dovolj pozne člene zaporedja  $x_{r+1}=g(x_r)$  velja:

$$C_1|x_r - \alpha|^p \le |x_{r+1} - \alpha| \le C_2|x_r - \alpha|^p$$

 $Vsak\ korak\ se\ \check{s}t.\ decimalk\ pomno\check{z}i\ s\ p.$ 

Naj bo g v okolici  $\alpha$  p-krat zvezno odvedlijva in naj velja  $g(\alpha) = \alpha$ ,  $g'(\alpha) = \cdots = g^{(p-1)}(\alpha) = 0$  in  $g^{(p)}(\alpha) \neq 0$ . Tedaj je red konvergence enak p.

## Standardni redi konvergence

p=1 ... linearna konvergenca p=2 ... kvadratična konvergenca

#### Tangentna (Newtonova) metoda

$$x_{r+1} = x_r - \frac{f(x_r)}{r}$$

Red konvergence:

- 2, če je  $\alpha$  enkratna ničla  $f'(\alpha) \neq 0$
- 3, če je  $f'(\alpha) \neq 0$  in  $f''(\alpha) = 0$
- 1. če je  $\alpha$  večkratna ničla  $f'(\alpha) = 0$

## Sekantna metoda

$$x_{r+1} = x_r - \frac{f(x_r)}{\frac{f(x_r) - f(x_{r-1})}{x_r - x_{r-1}}}$$

Red konvergence:  $\frac{\sqrt{5}+1}{2} \approx 1.62$ 

Metoda (f, f', f'')

$$x_{r+1} = x_r - \frac{f(x_r)}{f'(x_r)} - \frac{f''(x_r)f^2(x_r)}{2f'^3(x_r)}$$

Red konvergence: 3 (pri predpostavkah)

## Müllerjeva metoda

Na  $x_r$ ,  $x_{r-1}$ ,  $x_{r-2}$  napnemo parabolo, ničla parabole je naslednji približek.

$$p(x) = a(x - x_r)^2 + b(x - x_r) + c$$
$$x_{r+1} = x_r - \frac{2c}{b + \text{sign}(b)\sqrt{b^2 - 4ac}}$$

# Hallejeva metoda

$$x_{r+1} = x_r - \frac{2f(x_r)f'(x_r)}{2f'(x_r)^2 - f(x)f''(x)}$$

# Iskanje ničel polinoma

$$p_n(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_0, \quad a_n \neq 0$$

$$z_i^{(r+1)} = z_i^{(r)} - \frac{p(z_i^{(r)})}{\prod\limits_{\substack{k=1\\k\neq i}}^{n}(z_i^{(r)} - z_k^{(r)})}$$

## Metoda pridužene matrike

$$p_n(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_0, \quad a_n \neq 0$$

$$\mathbf{Durand\text{-}Kernerjeva\ metoda}$$

$$C_{p_n} = \begin{bmatrix} 0 & 1 & \dots & 0 & 0 \\ & 0 & & & \\ \vdots & & \ddots & & \vdots \\ & & & 1 & 0 \\ & & & & 1 & 0 \\ & & & & 0 & 1 \\ & & & & & 1 & 0 \\ & & & & & 0 & 1 \\ & & & & & & 1 & 0 \\ & & & & &$$

Lastne vrednosti (ničle  $\det(C - \lambda I)$ ) matrike  $C_{p_n}$ so ravno ničle polinoma  $p_n$ .